

نکات:

- ۱- مهلت تمرین عملی از تئوری بیشتر بوده و در lms مشخص است. در تمرین عملی هم کدهای نوشته شده و هم توضیح کامل پروژه و تحلیل نتایج را در lms بارگذاری کنید.
- ۲- پاسخ تمرینات در قالب فایل پی دی اف صرفاً در lms قرار گیرد.
- ۳- بخش تئوری تمرین توسط هر نفر جداگانه تحویل داده می شود، در lms دو تمرین جداگانه تئوری و عملی تعریف شده است.
- ۴- بخش عملی تمرین در گروه های حداکثر ۲ نفره انجام میشود. (گروه ها تا انتهای ترم یکسان باقی می ماند)
- ۵- تمرین عملی در زمانی که بعداً اعلام خواهد شد، توسط حل تمرین به صورت حضوری نیز تحویل گرفته می شود.

الف) بخش تئوری

- ۱- ایندکس معکوس (inverted index) و ماتریس رخداد (incidence matrix) را برای مستندات زیر رسم کنید.

سند اول : من در رشته مهندسی کامپیوتر تحصیل می کنم.

سند دوم : یکی از دروس رشته مهندسی کامپیوتر مبانی بازیابی اطلاعات است.

سند سوم: درس مبانی بازیابی اطلاعات درسی سه واحدی است.

سند چهارم: من این ترم فارغ التحصیل می شوم.

- ۲- با توجه به سوال یک به کوثری های زیر پاسخ دهید . به دو روش ماتریس رخداد و ایندکس معکوس

الف (بازیابی OR رشته

ب) رشته AND مبانی

ج) من AND (میشوم NOT)

د) مهندسی کامپیوتر AND (بازیابی AND اطلاعات) NOT

۳- یک سیستم بازیابی اطلاعات متنی که در دنیای واقعی مورد استفاده قرار می گیرد را مثال بزنید و اجزای اصلی معماری آن را بیان کرده و مفهوم کارایی Efficiency را در آن شرح دهید.

۴- با توجه به اندازه posting list ها ترتیب اجرای عملیات های پرس و جو زیر را مشخص کنید.

(computer OR lesson) AND (database OR me) AND (list OR city)

Term	Postings Size
Computer	316812
Lesson	46653
Database	107913
Me	271658
List	87009
City	213312

۵- برای کوئری های مشابح سوال سوم (conjunctive queries) آیا روش ترتیب پردازش وابسته به سایز Posting List ها همیشه کم هزینه ترین روش است؟ دلیل خود را توضیح دهید.

۶- درستی و نادرستی عبارات زیر را با توضیح مشخص کنید.

الف (ریشه یابی سبب افزایش اندازه واژگان (vocabulary) میشود.

ب) ریشه یابی باید در هنگام نمایه سازی (Indexing) فراخوانی شود نه در هنگام پردازش یک پرس وجو.

ج) در سیستم بازیابی بولی، ریشه یابی هرگز مقدار Recall را کاهش نمیدهد.

۷- قصد داریم بین لیست پست زیر (لیست اول با اشاره گر پرش) و نتایج عملیات گذشته (لیست دوم)، اشتراک بگیریم.

3 5 9 15 24 39 60 68 75 81 84 89 92 96 97 100 115

3 5 84 94 96 97 100 101 116

مطابق با الگوریتم intersection Postings در صفحه 26 اسلاید (the term vocabulary and postings lists) به

سوالات زیر پاسخ دهید.

الف) چند بار skip pointer طی می شود ؟ (یعنی p1 به skip (p2) پرس انجام می دهد)

ب) چه تعداد مقایسه postings توسط این الگوریتم درحالی که اشتراک دو لیست را انجام می دهد، اتفاق می افتد؟

ج) چه تعداد مقایسه postings باید انجام می پذیرفت، اگر posting list ها بدون استفاده از اشاره گرهای پرس، با هم اشتراک

۸- سند های زیر را در نظر بگیرید.

Doc1 : I am a student, and I currently attend the IR course.

Doc2 : I was a student; I have taken the IR course.

ایندکس مکانی (positional index) هر کدام از کلمات "student" و "I" را بدست آورید و به پرس وجوهای زیر پاسخ دهید.

کوثری اول : "I student"

کوثری دوم : "student I"

۹- چگونه یک سیستم IR میتواند استفاده از positional index و استفاده از لیست واژه ها (stop words) را با هم ترکیب کند؟ مشکل احتمالی در این فرآیند چیست و چگونه می توان آن را مدیریت کرد؟

۱۰- برای کلمات زیر ساختار درختی را برای ذخیره دیکشنری ایجاد کنید:

able, ability, about, back, backup, bad, badly

۱۱- کلمات دیکشنری و نمایه permuterm را به صورت درختی برای کلمه paper بنویسید و بگویید برای پرس و جوهای "pa*r" و "pe*" چه عبارتی جستجو می شود ؟

۱۲-

۱۳- فاصله کلمات "background" و "backboard" را توسط الگوریتم levenshtein بیابید.

(ب) بخش عملی

۱- برنامه ای بنویسید که تعدادی از اسناد به دلخواه دریافت کند و پرس و جو هایی را از کاربر دریافت کرده (شامل AND و OR و NOT) و به روش ایندکس معکوس اسناد مرتبط با آن را بازگرداند. اسناد را می توانید از مجموعه داده های متنی از مخزن های متداول وب مثل Kaggle و UCI برداشت کنید. تعداد سندها نیازی نیست که زیاد باشد، و انجام کارهای پیش پردازش در این بخش نیازی نیست. نتایج پرس و جو را تحلیل کرده و درستی آنها را بررسی کنید.

۲- فایل های متنی تمرین قبل را (در تعداد بیشتر) به وسیله نرم افزار Lucene ایندکس کنید. همه حروف را کوچک کنید و کلمات ایست را حذف کنید. ریشه یابی را به دلخواه خود می توانید انجام دهید (این امکانات در Lucene موجود است). سپس حداقل پنج پرس و جو مطرح کنید که عملگرهای and, or, not و جستجوی عبارت و پرس و جوی wildcard را شامل شوند و نتایج را بررسی کرده و گزارش کنید که آیا نتایج و رتبه بندی آنها منطقی هستند یا خیر.